

CLUSTERING ET INTELLIGENCE
ARTIFICIELLE

Segmentation des Projets de Developpement

Analyse du portefeuille de la BOAD a travers le
clustering K-Means et la classification hierarchique
de 200 projets de developpement synthetiques
dans l'espace UEMOA.

AKOTA Yao Jerome
Presente a la BOAD

JUIN 2026

1. Contexte et Objectifs

La Banque Ouest Africaine de Developpement (BOAD) finance des projets de developpement a travers les huit pays membres de l'Union Economique et Monetaire Ouest Africaine (UEMOA). Ces projets couvrent des secteurs strategiques tels que l'agriculture, les infrastructures, la sante, l'education et l'energie, avec des montants de financement varies.

Face a la diversite croissante de son portefeuille, la BOAD ressent le besoin d'outils d'analyse permettant de **segmenter ses projets** en groupes homogenes afin d'optimiser la gestion des risques, l'allocation des ressources et la prise de decision strategique.

Objectifs de l'etude :

- Appliquer des algorithmes de clustering (K-Means, classification hierarchique) sur un jeu de donnees synthetique de 200 projets.
- Determiner le nombre optimal de clusters a l'aide de la methode du coude et du coefficient de silhouette.
- Caracteriser chaque cluster et fournir des recommandations operationnelles pour la gestion du portefeuille de la BOAD.

2. Donnees et Methodologie

L'etude s'appuie sur un jeu de donnees synthetique de **200 projets de developpement** repartis sur **8 pays** de l'UEMOA et couvrant **8 secteurs** d'activite. Les variables cles incluent le montant de financement, la duree, le nombre de beneficiaires, le niveau de risque et le statut d'avancement.




Figure 1 : Repartition des projets par pays (gauche) et par secteur (droit)

Methodologie : Deux approches de clustering non supervise ont ete comparees. Le **K-Means** partitionne les donnees en k groupes en minimisant l'inertie intra-cluster, tandis que la **classification hierarchique ascendante** construit un arbre de regroupements progressifs (dendrogramme). Les donnees numeriques ont ete prealablement standardisees (StandardScaler) et les variables categorielles encodees. L'**Analyse en Composantes Principales (ACP)** a ete utilisee pour la visualisation bidimensionnelle des clusters.

3. Analyse Exploratoire

L'analyse exploratoire revele des disparites significatives dans les montants de financement entre les secteurs. La distribution des montants presente une asymetrie positive, avec une concentration des projets dans la tranche basse et quelques projets a fort financement.




Figure 2 : Distribution des montants de financement (gauche) et montants par secteur (droit)

La matrice de correlation met en evidence les relations entre les variables numeriques. On observe notamment une correlation positive entre le montant de financement et le nombre de beneficiaires, ainsi qu'entre la duree et le niveau de risque.




Figure 3 : Matrice de corrélation des variables numeriques

4. Resultats du Clustering

4.1 Determination du nombre optimal de clusters

La methode du coude et le coefficient de silhouette ont ete utilises pour determiner le nombre optimal de clusters. La courbe d'inertie montre un point d'inflexion clair, corrobore par les scores de silhouette les plus eleves.




Figure 4 : Methode du coude (gauche) et scores de silhouette (droit)

4.2 Resultats du K-Means et visualisation ACP

La projection ACP sur les deux premieres composantes principales permet de visualiser la separation des clusters obtenus par K-Means. Les clusters forment des groupes distincts dans l'espace reduit, confirmant la pertinence de la segmentation.




Figure 5 : Visualisation ACP des clusters (gauche) et profils radar par cluster (droit)

4.3 Profils des clusters

L'analyse des profils radar et des boites a moustaches par cluster permet d'identifier les caracteristiques distinctives de chaque groupe. Chaque cluster presente un profil spécifique en termes de montant, duree, beneficiaires et niveau de risque.




Figure 6 : Distribution des montants de financement par cluster

4.4 Comparaison avec la classification hiérarchique

La classification hiérarchique ascendante, visualisée par le dendrogramme, confirme la structure en groupes identifiée par le K-Means. La comparaison des deux méthodes montre une forte concordance dans la répartition des projets entre les clusters.




Figure 7 : Dendrogramme (gauche) et comparaison K-Means / Hiérarchique (droit)

5. Recommandations et Conclusion

5.1 Interprétation des clusters

L'analyse des clusters identifie des profils types dans le portefeuille de la BOAD :

- **Projets de grande envergure** : Montants élevés, longue durée, fort impact en termes de bénéficiaires. Nécessitent un suivi renforcé.
- **Projets à risque modéré** : Montants intermédiaires, équilibre entre risque et retour. Cible prioritaire pour l'optimisation.
- **Projets sociaux** : Faible financement mais fort impact social. À protéger et amplifier.
- **Projets à haut risque** : Nécessitent des mesures d'atténuation spécifiques et un suivi rapproché.

5.2 Recommandations pour la BOAD

- Adopter une approche de gestion différenciée par profil de cluster pour optimiser l'allocation des ressources.
- Mettre en place un système de suivi adapté au niveau de risque de chaque cluster.
- Utiliser les profils de clusters comme outil d'aide à la décision lors de l'évaluation de nouveaux projets.
- Envisager l'intégration de variables supplémentaires (impact environnemental, gouvernance) pour affiner la segmentation.

5.3 Limitations et perspectives

Cette étude repose sur des données synthétiques qui, bien que représentatives, ne captent pas l'ensemble de la complexité des projets réels de la BOAD. En perspective, il serait pertinent d'appliquer cette méthodologie sur les données historiques de la BOAD, d'explorer d'autres algorithmes (DBSCAN, Gaussian Mixture Models) et d'intégrer des techniques de deep learning pour une segmentation plus fine.

Ce rapport présente les résultats d'une étude réalisée dans le cadre d'un projet de Data Science appliquée à la segmentation du portefeuille de développement de la BOAD.